

Looped Transformer 实验进展报告

实验模式

交织成 $(x_1, y_1, x_2, y_2, \dots, x_k, y_k)$ ，根据历史的 $(x_1, y_1, \dots, x_i)$ 预测 y_i

基础配置

```
manual_config=dict(  
    batch_size=64,  
    num_blocks=20,  
    num_eff=15,  
    d_model=256,  
    num_heads=8,  
    pe_type=['learned_ape'],  
    x_init='zero',  
    init_std='auto',  
    residual_gate=(1, 1),  
    residual_gate_type='fixed',  
    optimizer_type='adamw',  
    lr=1e-3,  
    layer_weight_decay=1.0,  
    seq_weight_decay=1.0,  
    scheduler_type='cosine',  
)
```

Curriculum Learning

Curriculum Learning 是原论文在训练阶段引入的一种渐进式训练策略，使模型从简单的低维和短序列开始学习，逐步过渡到更复杂的高维和长序列。

线性和非线性回归任务

基础配置

```
d_x=20,  
seq_len=80,  
epochs=50,  
steps_per_epoch=200,
```

实验配置

```

params_groups=[
    {
        'experiment_name': 'Without Curriculum (Hard Mode)',
        'curriculum': {} #
    },
    {
        'experiment_name': 'With Curriculum (Perfect Path)',
        'curriculum': {
            'd_x': 5,
            'seq_len': 10,
            'duration_ratio': 0.8 # 前 80% 的 epochs 内逐步过渡到完整序列
        }
    }
]
results_lists = [
    (['1_ID_Baseline_sink_scores', '2_00D_Scale_x2_sink_scores', '3_00D_Scale_x2_sink_scores'],
    (['1_ID_Baseline_y_norm_ratio', '2_00D_Scale_x2_y_norm_ratio', '3_00D_Scale_x2_y_norm_ratio'],
    (['1_ID_Baseline_loss', '2_00D_Scale_x2_loss', '3_00D_Seq_Extrapolation_loss']
)]
eval_configs = [
    {'eval_name': '1_ID_Baseline', 'ood_kwargs': {}}, # 分布内基准
    {'eval_name': '2_00D_Scale_x2', 'ood_kwargs': {'x_scale': 2.0}}, ;
    {'eval_name': '3_00D_Seq_Extrapolation', 'ood_kwargs': {'seq_len': 10}}
]


```

线性回归

数据

$y_i = x_i @ W$ ，其中 W 是一个每批次随机生成的权重矩阵。

实验结果




结果分析

- 在线性回归任务中，如果不使用 Curriculum Learning，模型在训练初期会陷入一个全猜0的局部极小值，Loss 长时间停滞在1.0附近， $NormRatio = ||y_{true}|| / ||y_{pred}||$ 收敛于 0.0，表明模型完全没有学到有效的映射关系。
- 引入 Curriculum Learning 后，模型能够逐步适应更长的序列和更高维度的数据，Loss 稳步下降，Norm Ratio 也逐渐上升。在curriculum结束后的 20% 的 epochs 内，Loss 和 Norm Ratio 的下降不再波动，变得平滑，表明模型学会了正确的线性映射关系。

评估结果

包含两个实验的 sink score 随层深的演化折线图，以及 ID 与两种 OOD 场景下 Loss 与 Norm Ratio 的对比图。




非线性回归

数据

$y_i = 2 * 0.5 * \text{relu}(x_i @ W_1) @ W_2$, 其中 W_1 、 W_2 是每批次随机生成的权重矩阵和偏置向量。

实验结果




结果分析

- 在非线性回归任务中，模型在没有 Curriculum Learning 的情况下，在前半段时间内只学会了部分规律，Loss 在 0.74 附近震荡，Norm Ratio 在 0.52 左右徘徊，停滞不前；而在后半段时间内，模型突然顿悟，Loss 开始平滑稳定地下降，Norm Ratio 也迅速上升，表明模型在某个临界点（25~30 epochs 处，合 5000~6000 steps）上成功解开了非线性映射关系。

- 引入 Curriculum Learning 后，模型能够更早地适应非线性关系，Loss 和 Norm Ratio 的下降更加平滑稳定，没有明显的顿悟现象，表明模型在整个训练过程中都在持续地学习和优化非线性映射关系。

评估结果

包含两个实验的 sink score 随层深的演化折线图，以及 ID 与两种 OOD 场景下 Loss 与 Norm Ratio 的对比图。



Lorenz Attractor

基础配置

```
d_x=3,
d_y=3,
seq_len=300,
epochs=50,
steps_per_epoch=50,
optimizer_type='muon_adamw',
lorenz_kwargs=dict(dt=0.01, burn_in=500)
```

实验配置

```

param_groups = [
    {
        'experiment_name': 'Lorenz Without Curriculum (Hard Mode)',
        'curriculum': {} # 关闭课程学习, 一上来就啃 150 步长序列
    },
    {
        'experiment_name': 'Lorenz With Curriculum (Perfect Path)',
        # 删除了'd_x' 渐变 (因为d_x固定为3), 仅对时序步长进行课程演进
        'curriculum': {
            'seq_len': 20, # 课程从极短的 20 步 (10对点) 开始, 降低补
            'duration_ratio': 0.8 # 前 30 个 epoch 随着线性进度逐步拉长到
        }
    }
]

```

公式

洛伦兹系统的微分方程：


$$\dot{x} = \sigma(y - x), \dot{y} = x(\rho - z) - y, \dot{z} = xy - \beta z$$

其中 $\sigma = 10, \rho = 28, \beta = 8/3$ 。

数据

在数据生成中，通过rk4方法生成一段trajectory（记为 $r_1, \dots, r_k$ ）， $x=(r_1, r_2, \dots, r_{k-1})$ ， $y=(r_2, r_3, \dots, r_k)$ 。 $d_x = 3, d_y = 3$ 。模型的输入输出都是三维空间中的点序列，目标是学习从当前状态单步预测下一个状态的映射关系。配置为 $dt = 0.01$ ， $burn_in = 500$ （丢弃前 500 步的初始过渡态）


实验结果



结果分析

- 在洛伦兹系统的实验中，模型不管是否使用 Curriculum Learning，都能快速在1000 steps 内将 Loss 降到 0.1 以下，Norm Ratio 提升到 0.9 以上，但 Curriculum Learning 的引入使得模型训练效率大幅提升，取得同样的性能只需一半多一点的训练时间（因为seq_len小的时候训练耗时更短）。


评估结果



观察发现，Lorenz Attractor 任务中，sink score 的层深依赖曲线和上面的线性、非线性回归任务不同，呈现出在第 3~4 层出现一个明显的峰值，之后深层的 sink score 反而回落。

统一作图分析

Unified Dots: 18 Checkpoints Log-Log Mapping



Lorenz Attractor 任务的多步 rollout 评估分析



实验配置

- 150 步长的序列输入，模型完全自回归地盲推 1000 步，评估模型是否学会了混沌流形
- 采用已训练 5000 steps 的模型（此时 Loss 已经稳定在 0.01 以下，Norm Ratio 稳定在 0.9999 以上），分别在 ID 和 OOD 场景下进行评估，OOD 场景包括参数偏移

($\rho_{\text{shift}}=5.0$, 也就是 ρ 从 28 变为 33)。



结果分析

In Distribution 评估



可以看到，在 ID 场景下，模型能够非常准确地预测出混沌流形的轨迹，生成的轨迹与真实轨迹几乎一模一样，表明模型成功学会了洛伦兹系统的动力学规律。


Out of Distribution 评估




可以看到，形状仍然是光滑的蝴蝶翅膀流形，与ID场景下的轨迹非常相似，但是由于 ρ 的偏移，真实流形的尺度发生了明显的变化，模型生成的轨迹在尺度上明显比真实流形偏小，和ID场景的轨迹更接近，表明模型学会了洛伦兹系统的动力学规律，但对参数偏移的泛化能力有限。

对缺乏长期训练（只训练了不到1000 steps）的模型进行同样的评估


Ground Truth ID Orbit




Looped Transformer Autoregressive Rollout



Ground Truth OOD Orbit ($\rho = 33$)



Looped Transformer Autoregressive Rollout



可以看到，早期模型生成的轨迹也是蝴蝶翅膀的形状，在远离边界的区域与真实轨迹较为接近，但在边界附近发生了生硬的转折，尤其是在 OOD 场景下，好像把 OOD 的边界外真实三维数据“投影”到了 ID 的边界上，有明显的 C^1 不连续现象。